

Master en ingénierie des systèmes intelligents (ISI)

Module Machine Learning (avancée)

## **RAPPORT DE PROJET DE FIN DE MODULE**

# **Analyse intelligente du marché automobile marocain**

*Scraping, analyse exploratoire, prédiction des prix et segmentation des  
véhicules d'occasion*

Réalisé par :

Sofiane Jellouli

Yahya Cherif

Encadré par :

Pr. Zineb Gotti

## Résumé

Ce projet étudie le marché marocain des véhicules d'occasion à partir d'annonces publiques collectées sur Avito.ma. La démarche couvre toute la chaîne d'un projet de données : collecte automatisée des annonces, constitution d'un fichier structuré, nettoyage, analyse exploratoire, construction de modèles de régression, validation croisée, optimisation des hyperparamètres, segmentation par K-Means et test d'inférence sur un nouveau véhicule.

Le fichier initial contient 5 242 annonces et 31 variables. Après suppression des doublons, traitement des prix manquants et filtrage des valeurs aberrantes, 5 032 annonces ont été conservées, soit environ 96 % des données. Trois modèles de régression ont été comparés : la régression linéaire, Random Forest et XGBoost. Après optimisation avec GridSearchCV, le Random Forest optimisé est retenu comme modèle final avec une profondeur maximale de 15 et 60 arbres. Il obtient une MAE de 35 627,69 DH, un RMSE de 116 404,72 DH et un  $R^2$  de 0,5432 sur le jeu de test.

Le clustering montre que deux groupes décrivent le mieux la structure des annonces, avec un Silhouette Score de 0,4494. Le premier groupe rassemble des véhicules récents, mieux équipés et plus chers, tandis que le second contient la majorité des annonces, avec des véhicules plus anciens, moins équipés et plus kilométrés. Enfin, une Dacia Duster de 2021 avec 65 000 km est estimée à 175 787,67 DH.

## Abstract

This project analyzes the Moroccan used-car market using public listings collected from Avito.ma. The workflow covers the complete data-analysis process: automated data collection, dataset creation, preprocessing, exploratory analysis, regression modeling, cross-validation, hyperparameter optimization, K-Means clustering and price inference for a new vehicle.

The original dataset contains 5,242 listings and 31 variables. After removing duplicates, handling missing prices and filtering outliers, 5,032 observations remain. Three regression models are compared: Linear Regression, Random Forest and XGBoost. After GridSearchCV optimization, the optimized Random Forest is selected as the final model. It achieves an MAE of 35,627.69 DH, an RMSE of 116,404.72 DH and an  $R^2$  of 0.5432 on the test set.

The clustering analysis identifies two main vehicle segments, with a Silhouette Score of 0.4494. The final model estimates the price of a 2021 Dacia Duster with 65,000 km at 175,787.67 DH.

## Table des matières

|                                                               |    |
|---------------------------------------------------------------|----|
| Introduction générale .....                                   | 8  |
| Organisation du rapport .....                                 | 8  |
| 1. Contexte et objectifs du projet .....                      | 9  |
| 1.1 Contexte du marché automobile d'occasion .....            | 9  |
| 1.2 Objectif général .....                                    | 9  |
| 1.3 Objectifs spécifiques .....                               | 9  |
| 1.4 Démarche générale .....                                   | 10 |
| 2. Collecte des données par scraping .....                    | 10 |
| 2.1 Outils utilisés .....                                     | 10 |
| 2.2 Architecture en deux étapes .....                         | 11 |
| 2.3 Collecte des URL des annonces .....                       | 11 |
| 2.4 Extraction des caractéristiques .....                     | 12 |
| 2.5 Extraction du prix .....                                  | 12 |
| 2.6 Gestion des erreurs et des blocages .....                 | 13 |
| 2.7 Sauvegarde incrémentale et reprise automatique .....      | 13 |
| 3. Présentation et compréhension du dataset .....             | 14 |
| 3.1 Dimensions générales .....                                | 14 |
| 3.2 Nature des variables .....                                | 14 |
| 3.3 Variables principales retenues pour la modélisation ..... | 15 |
| 3.4 Qualité initiale des données .....                        | 15 |
| 4. Prétraitement des données .....                            | 16 |
| 4.1 Conversion du kilométrage .....                           | 16 |
| 4.2 Suppression des doublons .....                            | 16 |
| 4.3 Traitement des valeurs manquantes .....                   | 16 |
| 4.4 Valeurs aberrantes .....                                  | 17 |
| 4.5 Construction du nombre d'équipements .....                | 17 |
| 4.6 Encodage et standardisation .....                         | 17 |
| 5. Analyse exploratoire des données .....                     | 18 |
| 5.1 Statistiques descriptives .....                           | 18 |
| 5.2 Distribution du prix .....                                | 19 |
| 5.3 Comparaison des marques .....                             | 19 |
| 5.4 Corrélations numériques .....                             | 20 |

|                                                           |    |
|-----------------------------------------------------------|----|
| 5.5 Lecture générale du marché .....                      | 21 |
| 6. Construction des modèles de Machine Learning .....     | 21 |
| 6.1 Définition du problème .....                          | 21 |
| 6.2 Régression linéaire.....                              | 22 |
| 6.3 Random Forest.....                                    | 22 |
| 6.4 XGBoost.....                                          | 22 |
| 6.5 Pipeline complet .....                                | 22 |
| 6.6 Métriques utilisées .....                             | 23 |
| 7. Évaluation et optimisation .....                       | 23 |
| 7.1 Résultats sur le jeu de test .....                    | 23 |
| 7.2 Analyse des prédictions .....                         | 24 |
| 7.3 Validation croisée .....                              | 25 |
| 7.4 Optimisation du Random Forest avec GridSearchCV ..... | 25 |
| 7.5 Importance des variables.....                         | 26 |
| 7.6 Interprétation du niveau de performance .....         | 27 |
| 8. Segmentation des véhicules par clustering .....        | 27 |
| 8.1 Objectif.....                                         | 27 |
| 8.2 Choix du nombre de clusters .....                     | 28 |
| 8.3 Profil des clusters.....                              | 29 |
| 9. Inférence et tableau de bord analytique .....          | 30 |
| 9.1 Test sur une nouvelle voiture .....                   | 30 |
| 9.2 Indicateurs du tableau de bord.....                   | 30 |
| Conclusion générale .....                                 | 33 |
| Limites et perspectives .....                             | 33 |
| Limites du projet.....                                    | 33 |
| Perspectives d'amélioration .....                         | 34 |

## Tables des figures

|                                                                                                  |    |
|--------------------------------------------------------------------------------------------------|----|
| Figure 1: Code d'extraction des spécifications.....                                              | 11 |
| Figure 2: Recherche dans les liens des annonces.....                                             | 11 |
| Figure 3: importer des caractéristiques.....                                                     | 12 |
| Figure 4: Code de filtrage par expressions régulières .....                                      | 12 |
| Figure 5: Code de détection de reprise et filtrage des URL déjà collectées .....                 | 13 |
| Figure 6: Principales valeurs manquantes avant nettoyage .....                                   | 15 |
| Figure 7: Code de nettoyage, conversion et normalisation du kilométrage.....                     | 16 |
| Figure 8: Pipeline de prétraitement .....                                                        | 18 |
| Figure 9: Histogramme de la distribution des prix des annonces .....                             | 19 |
| Figure 10: Distribution des prix pour les principales marques .....                              | 19 |
| Figure 11: Matrice de corrélation des variables numériques .....                                 | 20 |
| Figure 12: construction du pipeline final avec transformation .....                              | 22 |
| Figure 13: Comparaison des modèles selon la MAE .....                                            | 23 |
| Figure 14: Comparaison des modèles selon la R2 .....                                             | 24 |
| Figure 15: prix réels et prix prédits par XGBoost.....                                           | 24 |
| Figure 16: Importance cumulée des variables.....                                                 | 26 |
| Figure 17: Silhouette Score pour k = 2, 3 et 4 .....                                             | 28 |
| Figure 18: Comparaison des profils des clusters.....                                             | 29 |
| Figure 19: Diagramme à barres des marques de voitures les plus présentes dans les annonces ..... | 31 |
| Figure 20: Diagramme à barres du prix médian des véhicules selon la marque (en DH) .....         | 31 |
| Figure 21: Nombre d'annonces automobiles selon le type de carburant .....                        | 32 |

## Liste des tableaux

|                                                                               |    |
|-------------------------------------------------------------------------------|----|
| Tableau 1: Bibliothèque et les outils .....                                   | 10 |
| Tableau 2: Indicateurs généraux du dataset .....                              | 14 |
| Tableau 3: Les catégories des variables.....                                  | 14 |
| Tableau 4: Les variables et les rôles.....                                    | 15 |
| Tableau 5: Traitement des valeurs manquantes .....                            | 17 |
| Tableau 6: Statistiques descriptives après nettoyage.....                     | 18 |
| Tableau 7: Dix marques les plus présentes .....                               | 21 |
| Tableau 8: Description des métriques d'évaluation .....                       | 23 |
| Tableau 9: Comparaison initiale des modèles.....                              | 23 |
| Tableau 10: Résultats de la validation croisée .....                          | 25 |
| Tableau 11: les paramètres du Random Forest .....                             | 25 |
| Tableau 12: Performance du Random Forest optimisé .....                       | 25 |
| Tableau 13: Classement des variables .....                                    | 26 |
| Tableau 14: l'évaluation du Silhouette Score selon le nombre de clusters..... | 28 |
| Tableau 15: Profil moyen des clusters.....                                    | 29 |
| Tableau 16: Description du véhicule testé.....                                | 30 |
| Tableau 17: indicateurs clés du tableau de bord .....                         | 30 |

## **Liste des abréviations**

CSV: Comma-Separated Values

EDA: Exploratory Data Analysis / Analyse exploratoire

MAE: Mean Absolute Error

RMSE: Root Mean Squared Error

R<sup>2</sup>: Coefficient de détermination

CV: Cross-validation / Validation croisée

HTML: HyperText Markup Language

DOM: Document Object Model

URL: Uniform Resource Locator

GPS: Global Positioning System

ABS: Antiblockiersystem / Système antiblocage

ESP: Electronic Stability Program

## Introduction générale

Le marché des véhicules d'occasion occupe une place importante dans les habitudes de consommation au Maroc. Pour un acheteur, la difficulté ne consiste pas seulement à trouver une annonce, mais surtout à déterminer si le prix proposé est cohérent avec les caractéristiques du véhicule. Deux voitures de même marque peuvent avoir des prix très différents selon l'année, le kilométrage, la motorisation, la boîte de vitesses, la puissance fiscale, les équipements ou encore la ville de publication.

Les plateformes de petites annonces contiennent une quantité importante d'informations, mais ces données sont dispersées dans des milliers de pages Web. Une analyse manuelle est donc lente et peu fiable. Le scraping permet d'automatiser la collecte de ces informations et de les transformer en un dataset structuré. Une fois les données nettoyées, les méthodes de Machine Learning peuvent être utilisées pour expliquer les facteurs liés au prix, construire un modèle prédictif et segmenter les véhicules en groupes homogènes.

Le projet présenté dans ce rapport suit cette logique. La collecte a été réalisée séparément à l'aide d'un script Python développé par le groupe. Le notebook principal commence à partir du fichier CSV obtenu et traite les étapes de préparation, d'analyse et de modélisation. Cette séparation permet de conserver un code clair : le script de scraping est responsable de la collecte, tandis que le notebook est consacré à l'exploitation des données.

**Problématique :** Comment exploiter les annonces automobiles publiées sur Avito.ma afin d'identifier les facteurs qui influencent le prix, d'estimer le prix d'un véhicule et de former des groupes de voitures similaires ?

## Organisation du rapport

Le rapport commence par le contexte et les objectifs. Il décrit ensuite le fonctionnement du scraper, les variables collectées et les mécanismes de sauvegarde. Les chapitres suivants présentent le prétraitement, l'analyse exploratoire, les modèles de régression, la validation croisée, l'optimisation des hyperparamètres, le clustering, l'inférence et le tableau de bord. Le rapport se termine par la conclusion générale, les limites du projet et les perspectives d'amélioration.

# 1. Contexte et objectifs du projet

## 1.1 Contexte du marché automobile d'occasion

Une annonce automobile combine des variables numériques et catégorielles. Les variables numériques décrivent notamment le prix, l'année, le kilométrage, la puissance fiscale et le nombre de portes. Les variables catégorielles indiquent la marque, le modèle, la ville, le type de carburant, la boîte de vitesses, l'origine ou l'état. Plusieurs équipements sont également présents sous forme booléenne, par exemple les airbags, la climatisation, l'ABS ou la caméra de recul.

Cette diversité rend le problème intéressant du point de vue du Machine Learning. Le prix ne suit pas une relation parfaitement linéaire et dépend de nombreuses interactions. Une voiture récente et automatique peut être plus chère, mais l'effet dépend aussi de la marque, du modèle et du niveau d'équipement. Il est donc nécessaire de comparer un modèle linéaire avec des modèles capables de représenter des relations non linéaires.

## 1.2 Objectif général

L'objectif général est de construire une chaîne simple et reproductible permettant de transformer des annonces Web en informations utiles sur le marché automobile marocain.

## 1.3 Objectifs spécifiques

- Collecter automatiquement les liens et les détails des annonces de voitures d'occasion.
- Construire un dataset structuré dépassant le minimum de 1 000 observations.
- Décrire et nettoyer les variables collectées.
- Étudier la distribution des prix et les relations entre les caractéristiques.
- Comparer plusieurs algorithmes de régression.
- Évaluer les modèles avec le MAE, le RMSE et le  $R^2$ .
- Utiliser la validation croisée et GridSearchCV.
- Segmenter les véhicules avec K-Means et interpréter les clusters.
- Tester une prédiction sur une nouvelle voiture.
- Présenter les résultats sous la forme d'un tableau de bord analytique.

## 1.4 Démarche générale

- Collecte : parcours des pages de résultats, collecte des URL et extraction des détails.
- Stockage : sauvegarde progressive en CSV et export Excel.
- Nettoyage : conversion, déduplication et filtrage des anomalies.
- Analyse : statistiques descriptives et visualisations.
- Modélisation et évaluation : trois algorithmes, jeu de test, validation croisée et GridSearchCV.
- Segmentation et exploitation : application de K-Means, inférence sur un nouveau véhicule et réalisation d'un tableau de bord analytique.

## 2. Collecte des données par scraping

### 2.1 Outils utilisés

Le scraper est développé en Python. Selenium pilote un navigateur Chrome afin de charger les pages dynamiques et de cliquer sur les éléments cachés. BeautifulSoup analyse ensuite le contenu HTML. pandas est utilisé pour relire, consolider et exporter les données. Le module csv permet une sauvegarde incrémentale ligne par ligne. Enfin, logging fournit des messages de suivi et facilite le diagnostic des erreurs.

Tableau 1: Bibliothèque et les outils

| Bibliothèque / outil    | Rôle                                                                              |
|-------------------------|-----------------------------------------------------------------------------------|
| Python                  | Langage principal du projet.                                                      |
| Selenium                | Navigation automatisée, chargement des pages et interaction avec les boutons.     |
| undetected-chromedriver | Création du navigateur Chrome avec une configuration adaptée aux pages protégées. |
| BeautifulSoup           | Analyse du HTML et extraction des valeurs.                                        |
| pandas                  | Lecture et export des datasets CSV et Excel.                                      |
| re                      | Expressions régulières pour les URL, les prix et les valeurs numériques.          |
| logging                 | Journalisation de la progression, des avertissements et des erreurs.              |
| csv / pathlib           | Sauvegarde progressive et gestion des fichiers.                                   |

## 2.2 Architecture en deux étapes

La collecte est divisée en deux étapes. Cette organisation réduit le risque de perdre tout le travail en cas d'interruption et permet de reprendre facilement le processus.

1. Collecte des URL : le script parcourt jusqu'à 150 pages de résultats et construit un ensemble d'URL uniques.
2. Extraction des détails : chaque URL est visitée afin de lire les caractéristiques, les équipements et le prix.

### Extrait 1 - Paramètres principaux de la collecte

```
BASE_URL_RECHERCHE = "https://www.avito.ma/fr/maroc/voitures_d_occasion-%C3%A0_vendre"
NB_PAGES_RECHERCHE_MAX = 250      # pages de résultats à parcourir pour collecter les liens
OBJECTIF_MIN_ANNONCES = 5000      # nb minimum d'URLs à collecter avant de passer à l'étape 2
DELAI_MIN = 2.5
DELAI_MAX = 5.0
FICHIER_URLS = "urls_annonces.csv"      # sauvegarde intermédiaire (étape 1)
FICHIER_SORTIE = "avito_car_dataset.csv" # dataset final (étape 2)
```

Figure 1: Code d'extraction des spécifications

## 2.3 Collecte des URL des annonces

Pour chaque page de résultats, le script construit l'URL correspondante et charge la page dans Chrome. BeautifulSoup recherche ensuite les liens se terminant par .htm. Deux expressions régulières sont utilisées : la première vise les chemins habituels des annonces automobiles, tandis que la seconde constitue un mécanisme de secours basé sur l'identifiant numérique final de l'annonce.

Les liens sont stockés dans un ensemble Python, ce qui supprime automatiquement les doublons. Le processus s'arrête lorsque l'objectif est largement atteint ou après trois pages vides consécutives. Les URL collectées sont enregistrées dans urls\_annonces.csv avant le passage à la deuxième étape.

### Extrait 2 - Recherche robuste des liens d'annonces

```
liens = soup.find_all("a", href=re.compile(r"/voitures(?:_d_occasion)?/[^\s]+\s\.htm$"))

if not liens:
    # Filet de sécurité : peu importe le segment du milieu, une
    # annonce Avito se termine TOUJOURS par "<identifiant numérique>.htm"
    # (ex: ..._58128799.htm). Ce pattern est beaucoup plus stable que
    # le nom exact du dossier ("voitures", "voitures_d_occasion", etc.)
    liens = soup.find_all("a", href=re.compile(r"_d{6,}\s\.htm$"))
    if liens:
        logger.info(f" (trouvé via le pattern de secours _ID.htm : {len(liens)} lien(s))")
```

Figure 2: Recherche dans les liens des annonces

## 2.4 Extraction des caractéristiques

Chaque annonce contient des caractéristiques principales et des équipements. Les caractéristiques sont identifiées à partir du texte alternatif des icônes, par exemple « Année-Modèle », « Marque » ou « Kilométrage ». Cette stratégie est plus stable que l'utilisation directe de classes CSS, car les classes peuvent changer fréquemment lorsque le site est mis à jour.

Le script clique également sur les boutons « Voir plus » afin d'afficher les caractéristiques et équipements cachés. Pour les équipements, la présence d'une icône est traduite par True et son absence par False.

### Extrait 3 - Extraction des caractéristiques et équipements

```
for champ in CHAMPS_SPEC:
    if champ in ("Ville", "Secteur"):
        continue
    resultat[champ] = extraire_valeur_spec(soup, champ)
# Équipements : présence de l'icône = True, sinon False
for equip in CHAMPS_EQUIPEMENTS:
    resultat[equip] = soup.find("img", alt=equip) is not None
resultat["Prix"] = extraire_prix(soup)
```

Figure 3: importer des caractéristiques

## 2.5 Extraction du prix

Le prix nécessite un traitement spécifique. Une page peut afficher le prix réel, une mensualité de financement ou une valeur par défaut du simulateur. La fonction extraire\_prix commence près du titre de l'annonce, puis utilise une expression régulière qui exclut les montants suivis de « par mois ». Les valeurs inférieures à 1 000 DH sont ignorées afin d'éviter notamment les faux prix égaux à zéro.

### Extrait 4 - Filtrage des montants pour récupérer le prix réel

```
matches = re.findall(r"([\d][\d\s]{2,})\s?DH(?:!\s*/\s*mois)(?!*\s*Par mois)", texte)
for m in matches:
    valeur = int(re.sub(r"^\d", "", m))
    if valeur >= 1000:
        return valeur
```

Figure 4: Code de filtrage par expressions régulières

## 2.6 Gestion des erreurs et des blocages

- Timeout de chargement : l'annonce ou la page est ignorée et l'erreur est enregistrée.
- Challenge Cloudflare : le script attend plusieurs secondes et vérifie à nouveau le titre de la page.
- Bouton inaccessible : le clic classique est remplacé par un clic JavaScript.
- Page vide ou structure inattendue : une capture d'écran et le HTML peuvent être sauvegardés pour diagnostic.
- Champ absent : la valeur None est conservée et sera traitée plus tard pendant le prétraitement.
- Délais aléatoires : une pause entre 2,5 et 5 secondes est ajoutée entre les requêtes.

## 2.7 Sauvegarde incrémentale et reprise automatique

Après chaque annonce correctement extraite, une nouvelle ligne est ajoutée au fichier `avito_car_dataset.csv`. Si le programme est interrompu, il relit le fichier existant, récupère les URL déjà traitées et continue uniquement avec les URL restantes. Cette reprise automatique est particulièrement importante pour un scraping de plusieurs milliers d'annonces.

### Extrait 5 - Reprise de la collecte après interruption

```
if Path(FICHIER_SORTIE).exists():
    try:
        df_existant = pd.read_csv(FICHIER_SORTIE, encoding="utf-8-sig")
        urls_deja_faites = set(df_existant["Lien"].dropna().tolist())
        logger.info(
            f"Reprise détectée : {len(urls_deja_faites)} annonce(s) déjà "
            f"présente(s) dans {FICHIER_SORTIE}, elles seront ignorées."
        )
    except (pd.errors.EmptyDataError, KeyError):
        pass

urls_a_faire = [u for u in urls if u not in urls_deja_faites]
```

Figure 5: Code de détection de reprise et filtrage des URL déjà collectées

À la fin de l'exécution, le fichier CSV est relu et une version Excel est également générée. Le dataset brut utilisé dans ce projet contient finalement 5 242 annonces, ce qui dépasse largement le minimum de 1 000 observations demandé.

### 3. Présentation et compréhension du dataset

#### 3.1 Dimensions générales

Tableau 2: Indicateurs généraux du dataset

| Indicateur                 | Valeur |
|----------------------------|--------|
| Nombre de lignes initiales | 5 242  |
| Nombre de colonnes         | 31     |
| Doublons détectés          | 22     |
| Lignes après nettoyage     | 5 032  |
| Taux de conservation       | 96,0 % |

Les 31 colonnes comprennent un lien vers l'annonce, des informations géographiques, des caractéristiques techniques, seize équipements booléens et le prix. Le lien sert principalement à identifier une annonce et à supprimer les doublons. Il n'est pas utilisé directement comme variable explicative dans les modèles.

#### 3.2 Nature des variables

Tableau 3: Les catégories des variables

| Catégorie               | Variables ou rôle                                                               |
|-------------------------|---------------------------------------------------------------------------------|
| Variables numériques    | Année, kilométrage, puissance fiscale, nombre de portes                         |
| Variable cible          | Prix du véhicule en DH                                                          |
| Variables catégorielles | Ville, secteur, marque, modèle, carburant, boîte, origine, première main, état. |
| Variables booléennes    | Présence ou absence de chacun des seize équipements.                            |
| Variable construite     | Nombre équipements, obtenu par somme des indicateurs booléens.                  |
| Identifiant             | Lien de l'annonce, utilisé pour la déduplication.                               |

### 3.3 Variables principales retenues pour la modélisation

Tableau 4: Les variables et les rôles

| Variable           | Rôle possible dans le prix              |
|--------------------|-----------------------------------------|
| Année-Modèle       | Ancienneté et modernité.                |
| Kilométrage        | Niveau d'utilisation.                   |
| Puissance fiscale  | Motorisation et gamme.                  |
| Nombre de portes   | Type de carrosserie.                    |
| Nombre équipements | Niveau d'équipement.                    |
| Ville              | Effet local du marché.                  |
| Marque             | Positionnement du constructeur.         |
| Modèle             | Différences entre gammes.               |
| Type de carburant  | Diesel, essence, hybride ou électrique. |
| Boîte de vitesses  | Manuelle ou automatique.                |

### 3.4 Qualité initiale des données




Figure 6: Principales valeurs manquantes avant nettoyage

Le secteur est absent dans 2 352 annonces, soit environ 44,9 %. La première main, l'origine, le nombre de portes et l'état présentent également de nombreuses valeurs manquantes. En revanche, la marque, le modèle, le kilométrage et la boîte de vitesses sont presque toujours renseignés. Le prix manque dans 177 lignes, qui sont supprimées car elles ne peuvent pas être utilisées pour l'apprentissage supervisé.

## 4. Prétraitement des données

### 4.1 Conversion du kilométrage

Le kilométrage peut apparaître sous une forme exacte ou sous la forme d'une tranche, par exemple « 100 000 - 109 999 ». Une fonction utilisant les expressions régulières extrait les nombres. Lorsqu'une tranche est détectée, la moyenne des deux bornes est utilisée. Cette transformation permet d'obtenir une variable numérique compatible avec les modèles.

#### Extrait 6 - Conversion du kilométrage

```
def convertir_kilometrage(valeur):
    if pd.isna(valeur):
        return np.nan

    texte = str(valeur).replace("\xa0", " ").strip()
    nombres = re.findall(r"\d[\d ]*", texte)
    nombres = [int(x.replace(" ", "")) for x in nombres]

    if len(nombres) == 0:
        return np.nan

    if "-" in texte and len(nombres) >= 2:
        return (nombres[0] + nombres[1]) / 2

    return nombres[0]
```

Figure 7: Code de nettoyage, conversion et normalisation du kilométrage

### 4.2 Suppression des doublons

La colonne Lien est utilisée comme identifiant. Le dataset contenait 22 URL répétées. Elles ont été supprimées avec `drop_duplicates(subset=['Lien'])`. Cette opération évite qu'une même annonce influence plusieurs fois le modèle.

### 4.3 Traitement des valeurs manquantes

Les lignes sans prix sont supprimées, car le prix est la variable cible. Les autres valeurs manquantes ne sont pas supprimées systématiquement afin de conserver le maximum d'observations. Dans le pipeline de Machine Learning, les variables numériques sont imputées par la médiane et les variables catégorielles par la modalité la plus fréquente.

Tableau 5: Traitement des valeurs manquantes

| Type de manque          | Traitement                                                        |
|-------------------------|-------------------------------------------------------------------|
| Prix                    | Suppression de la ligne.                                          |
| Variables numériques    | Imputation par la médiane dans le pipeline.                       |
| Variables catégorielles | Imputation par la modalité la plus fréquente.                     |
| Équipements absents     | Valeur False lors du calcul du nombre d'équipements.              |
| Variables non retenues  | Conservées dans le dataset, sans être utilisées dans les modèles. |

#### 4.4 Valeurs aberrantes

Certaines valeurs extrêmes peuvent provenir d'une erreur de saisie, d'un faux prix ou d'une mauvaise extraction. Des règles simples sont donc appliquées afin de conserver des annonces cohérentes :

- Prix compris entre 20 000 et 3 000 000 DH.
- Kilométrage compris entre 0 et 500 000 km lorsqu'il est renseigné.
- Année-Modèle comprise entre 1980 et 2026 lorsqu'elle est renseignée.

Après l'ensemble du nettoyage, 5 032 lignes restent disponibles, contre 5 242 au départ. 210 lignes ont donc été retirées et 96,0 % du dataset a été conservé.

#### 4.5 Construction du nombre d'équipements

Les seize colonnes d'équipements sont additionnées pour créer Nombre équipements. Cette variable synthétique représente le niveau d'équipement global et réduit la complexité du modèle. Une valeur de 0 correspond à aucune option détectée, tandis que la valeur maximale observée est 16.

#### 4.6 Encodage et standardisation

Les modèles de Machine Learning utilisés ne peuvent pas exploiter directement les variables textuelles. OneHotEncoder transforme chaque modalité en une colonne binaire. Par exemple, la variable Marque devient plusieurs colonnes telles que Marque\_Dacia, Marque\_Renault ou Marque\_Mercedes-Benz. `handle_unknown='ignore'` évite une erreur lors de la prédiction d'une catégorie non vue pendant l'entraînement.

Les variables numériques sont standardisées avec StandardScaler. La standardisation est particulièrement utile pour la régression linéaire et pour K-Means, car elle évite qu'une variable à grande échelle, comme le kilométrage, domine les autres variables.

#### Extrait 7 - Pipeline de prétraitement

```

traitemment_numerique = Pipeline([
    ("imputation", SimpleImputer(strategy="median")),
    ("standardisation", StandardScaler())
])

traitemment_categoriel = Pipeline([
    ("imputation", SimpleImputer(strategy="most_frequent")),
    ("encodage", OneHotEncoder(
        handle_unknown="ignore",
        min_frequency=5
    ))
])

```

Figure 8: Pipeline de prétraitement

## 5. Analyse exploratoire des données

### 5.1 Statistiques descriptives

Tableau 6: Statistiques descriptives après nettoyage

| Variable           | Moyenne    | Médiane    | Écart-type | Minimum   | Maximum     |
|--------------------|------------|------------|------------|-----------|-------------|
| Prix               | 163 231,02 | 115 000,00 | 171 807,46 | 21 000,00 | 2750 000,00 |
| Année-Modèle       | 2 013,43   | 2 014,00   | 6,10       | 1 980,00  | 2 026,00    |
| Kilométrage        | 129 548,87 | 124 999,50 | 86 384,94  | 0,00      | 474 999,50  |
| Puissance fiscale  | 7,37       | 7,00       | 2,06       | 4,00      | 41,00       |
| Nombre de portes   | 4,90       | 5,00       | 0,43       | 3,00      | 5,00        |
| Nombre équipements | 3,87       | 4,00       | 4,13       | 0,00      | 16,00       |

Le prix moyen est de 163 231 DH, alors que le prix médian est de 115 000 DH. Cette différence montre que quelques véhicules très chers tirent la moyenne vers le haut. L'année moyenne est 2 013,4 et le kilométrage médian est de 125 000 km.

## 5.2 Distribution du prix




Figure 9: Histogramme de la distribution des prix des annonces

La distribution du prix est fortement asymétrique. La majorité des annonces est concentrée dans les prix faibles et moyens, tandis qu'un petit nombre de véhicules haut de gamme présente des prix très élevés. Pour limiter l'influence de ces valeurs élevées pendant l'apprentissage, une transformation logarithmique  $\log(1 + \text{prix})$  est appliquée à la variable cible avec `TransformedTargetRegressor`. Après la prédiction, la transformation inverse est utilisée afin de retrouver les prix en dirhams.

## 5.3 Comparaison des marques




Figure 10: Distribution des prix pour les principales marques

Le boxplot montre des différences de positionnement entre les marques. Les marques ne suffisent toutefois pas à expliquer le prix : la dispersion interne reste importante, car chaque marque contient des modèles, des années et des kilométrages très différents. Pour cette raison, la variable Modèle est conservée en plus de la Marque.

## 5.4 Corrélations numériques




Figure 11: Matrice de corrélation des variables numériques

Les corrélations positives les plus élevées avec le prix concernent le nombre d'équipements (0,42) et l'année du véhicule (0,40). La puissance fiscale présente également une corrélation positive avec le prix (0,35). À l'inverse, le kilométrage est négativement corrélé au prix (-0,19), ce qui signifie que les véhicules plus kilométrés ont généralement un prix plus faible.

## 5.5 Lecture générale du marché

Tableau 7: Dix marques les plus présentes

| Marque        | Nombre d'annonces |
|---------------|-------------------|
| Volkswagen    | 680               |
| Renault       | 616               |
| Dacia         | 537               |
| Mercedes-Benz | 437               |
| Peugeot       | 372               |
| Hyundai       | 355               |
| Ford          | 301               |
| Fiat          | 205               |
| Audi          | 199               |
| Citroen       | 189               |

Volkswagen est la marque la plus représentée avec 680 annonces, suivie de Renault (616) et Dacia (537). Le diesel domine très largement le dataset avec 4 445 annonces. Cette structure doit être prise en compte lors de l'interprétation : les résultats décrivent principalement les véhicules diesel et les marques les plus fréquentes dans l'échantillon.

## 6. Construction des modèles de Machine Learning

### 6.1 Définition du problème

Le prix est une variable numérique continue. Le problème principal est donc un problème de régression supervisée. Le dataset est divisé en 80 % pour l'entraînement et 20 % pour le test, avec `random_state=42` afin de reproduire la même séparation.

La variable cible est transformée avec `log1p` avant l'entraînement. Cette transformation réduit l'influence des prix extrêmes. Les prédictions sont reconverties dans l'unité d'origine avec `expm1`, ce qui permet de calculer les métriques directement en dirhams.

## 6.2 Régression linéaire

La régression linéaire sert de modèle simple de référence. Elle suppose que la variation du prix peut être représentée par une combinaison linéaire des variables après encodage. Son avantage est sa simplicité et sa rapidité. Sa limite principale est sa difficulté à représenter les interactions complexes entre la marque, le modèle, l'année et les autres caractéristiques.

## 6.3 Random Forest

Random Forest combine plusieurs arbres de décision construits sur des sous-échantillons des données et des variables. La prédiction finale est la moyenne des prédictions des arbres. Ce modèle peut représenter des effets non linéaires et des interactions sans exiger une formule explicite. Dans la première comparaison, 50 arbres, une profondeur maximale de 12 et un minimum de deux observations par feuille sont utilisés.

## 6.4 XGBoost

XGBoost construit des arbres successifs, chaque nouvel arbre essayant de corriger les erreurs des arbres précédents. Les paramètres choisis restent volontairement simples : 60 arbres, profondeur 4, taux d'apprentissage 0,07, sous-échantillonnage de 90 % des lignes et de 90 % des colonnes.

## 6.5 Pipeline complet

Chaque modèle est intégré dans le même pipeline de prétraitement. Cette organisation garantit que l'imputation, la standardisation et l'encodage sont appris uniquement à partir des données d'entraînement. Elle évite également de répéter manuellement les mêmes transformations pour chaque algorithme.

### Extrait 8 - Pipeline de modélisation et transformation de la cible

```
pipeline = Pipeline([
    ("preparation", preparation),
    ("modele", modele)
])

modele_final = TransformedTargetRegressor(
    regressor=pipeline,
    func=np.log1p,
    inverse_func=np.expm1
)
```

Figure 12: construction du pipeline final avec transformation

## 6.6 Métriques utilisées

Tableau 8: Description des métriques d'évaluation

| Métrique       | Interprétation                                                                                                                 |
|----------------|--------------------------------------------------------------------------------------------------------------------------------|
| MAE            | Moyenne de la valeur absolue des erreurs. Facile à interpréter en DH.                                                          |
| RMSE           | Racine de la moyenne des erreurs quadratiques. Pénalise davantage les grandes erreurs.                                         |
| R <sup>2</sup> | Part de la variation des prix expliquée par le modèle. Plus la valeur est élevée et proche de 1, meilleure est la performance. |

## 7. Évaluation et optimisation

### 7.1 Résultats sur le jeu de test

Tableau 9: Comparaison initiale des modèles

| Modèle              | MAE          | RMSE          | R <sup>2</sup> |
|---------------------|--------------|---------------|----------------|
| Random Forest       | 37554.55 DH  | 118172.63 DH  | 0,53           |
| XGBoost             | 38541.66 DH  | 116815.75 DH  | 0,54           |
| Régression linéaire | 36 965.03 DH | 122 117.96 DH | 0,50           |




Figure 13: Comparaison des modèles selon la MAE




Figure 14: Comparaison des modèles selon la R²

La régression linéaire obtient la plus faible MAE, mais son RMSE est le plus élevé et son  $R^2$  est le plus faible. Cela signifie qu'elle produit des erreurs absolues généralement raisonnables, mais qu'elle commet davantage de grandes erreurs. XGBoost obtient le meilleur RMSE et le meilleur  $R^2$  parmi les trois modèles initiaux. Random Forest présente des performances proches et sera ensuite optimisé avec GridSearchCV.

## 7.2 Analyse des prédictions




Figure 15: prix réels et prix prédits par XGBoost

Les points proches de la diagonale correspondent à des prédictions proches des prix réels. La dispersion augmente pour les véhicules les plus chers, qui sont moins nombreux et plus hétérogènes. Le modèle est donc plus précis pour les voitures aux prix faibles et moyens que pour les véhicules très haut de gamme.

### 7.3 Validation croisée

Tableau 10: Résultats de la validation croisée

| Modèle              | MAE moyenne - 5 plis | Écart-type  |
|---------------------|----------------------|-------------|
| Régression linéaire | 39 143.78 DH         | 7 195.47 DH |
| XGBoost             | 40 540.11 DH         | 8 848.63DH  |
| Random Forest       | 41 465.37 DH         | 8 249.10 DH |

La validation croisée à cinq plis répète l'évaluation sur plusieurs découpages du jeu d'entraînement. La régression linéaire obtient la plus faible MAE moyenne, suivie de XGBoost et de Random Forest. Les écarts-types restent élevés, ce qui montre que les performances varient selon les annonces présentes dans chaque pli, notamment à cause des véhicules très chers et moins nombreux.

### 7.4 Optimisation du Random Forest avec GridSearchCV

GridSearchCV teste plusieurs combinaisons du nombre d'arbres et de la profondeur maximale. La recherche est réalisée uniquement sur un échantillon du jeu d'entraînement avec une validation croisée à cinq plis. Après la sélection des meilleurs paramètres, le modèle est réentraîné sur l'ensemble du jeu d'entraînement, puis évalué sur le jeu de test indépendant.

Tableau 11: les paramètres du Random Forest

| Hyperparamètre | Valeurs testées | Meilleure valeur |
|----------------|-----------------|------------------|
| n_estimators   | 40, 60          | 60               |
| max_depth      | 10, 15          | 15               |

Tableau 12: Performance du Random Forest optimisé

| MAE optimisée | RMSE optimisé | R <sup>2</sup> optimisé |
|---------------|---------------|-------------------------|
| 35627.68 DH   | 116404.72 DH  | 0,5432                  |

La meilleure combinaison utilise 60 arbres et une profondeur maximale de 15. Après réentraînement sur l'ensemble du jeu d'entraînement, le Random Forest optimisé obtient une MAE de 35 627,69 DH, un RMSE de 116 404,72 DH et un  $R^2$  de 0,5432. Il explique ainsi environ 54,3% de la variation des prix. L'amélioration reste modérée, car certaines informations importantes, comme l'état mécanique réel ou l'historique d'entretien, ne sont pas disponibles dans les annonces.

## 7.5 Importance des variables




Figure 16: Importance cumulée des variables

Tableau 13: Classement des variables

| Variable           | Importance cumulée |
|--------------------|--------------------|
| Boite de vitesses  | 0.329754           |
| Année-Modèle       | 0.311517           |
| Puissance fiscale  | 0.091580           |
| Modèle             | 0.080758           |
| Marque             | 0.057081           |
| Nombre équipements | 0.046662           |
| ville              | 0.035056           |
| Kilométrage        | 0.029135           |
| Type de carburant  | 0.017809           |
| Nombre de portes   | 0.000648           |

La boîte de vitesses et l'année du véhicule sont les variables les plus importantes pour le modèle. Dans le dataset, une boîte automatique est souvent associée à des voitures plus récentes, plus équipées et plus chères. L'importance indique qu'une variable aide le modèle à prédire le prix, mais elle ne prouve pas une relation de causalité.

La marque reste également importante. Après l'encodage One-Hot, son importance est répartie entre plusieurs colonnes correspondant aux différentes marques. Les importances ont donc été regroupées afin de comparer correctement la marque avec l'année, le kilométrage, le modèle et les autres variables.

## 7.6 Interprétation du niveau de performance

Un  $R^2$  de **0,5432** signifie que le modèle explique environ **54,3 %** de la variation des prix observés. Ce résultat reste cohérent avec la nature du problème, car le prix d'une voiture dépend aussi de facteurs absents du dataset, comme l'état mécanique réel, l'historique d'entretien, la finition exacte, la qualité des photos, l'urgence du vendeur et la marge de négociation..

**Lecture pratique :** une MAE de **35 627,69 DH** signifie que l'écart absolu moyen entre le prix prédit et le prix affiché est d'environ **35 600 DH** sur le jeu de test.

## 8. Segmentation des véhicules par clustering

### 8.1 Objectif

La régression cherche à prédire le prix. Le clustering répond à une autre question : existe-t-il des groupes naturels de voitures partageant des caractéristiques proches ? K-Means est appliqué sur cinq variables standardisées : prix, année, kilométrage, puissance fiscale et nombre d'équipements.

## 8.2 Choix du nombre de clusters




Figure 17: Silhouette Score pour k = 2, 3 et 4

Tableau 14: l'évaluation du Silhouette Score selon le nombre de clusters

| Nombre de clusters | Silhouette Score |
|--------------------|------------------|
| 2                  | 0,4494           |
| 3                  | 0,3064           |
| 4                  | 0,3148           |

Le meilleur score est obtenu pour deux clusters avec 0,449. Ce choix produit des groupes plus séparés que les solutions à trois ou quatre clusters. K-Means est donc relancé avec  $k = 2$  sur l'ensemble nettoyé.

### 8.3 Profil des clusters

Tableau 15: Profil moyen des clusters

| Cluster   | Prix moyen    | Année    | Kilométrage   | Puissance | Équipements | Effectif |
|-----------|---------------|----------|---------------|-----------|-------------|----------|
| Cluster 0 | 444 581.65 DH | 2 020,42 | 89 574.89 km  | 8,85      | 12,4        | 594      |
| Cluster 1 | 125 573.91 DH | 2 012,49 | 134 910.02 km | 7,18      | 2,72        | 4 438    |




Figure 18: Comparaison des profils des clusters

Le cluster 0 rassemble 594 annonces. Il correspond aux véhicules les plus récents, les moins kilométrés, les plus puissants, les mieux équipés et les plus chers. Son prix moyen est de **444 581,65 DH** et son année moyenne est de **2020,42**.

Le cluster 1 regroupe 4 438 annonces, soit la majorité du marché observé. Les véhicules sont plus anciens, davantage kilométrés et moins équipés. Leur prix moyen est de **125 573,91 DH** et leur année moyenne est de **2012,49**. Cette segmentation permet de distinguer les véhicules récents et haut de gamme des véhicules plus courants et accessibles.

## 9. Inférence et tableau de bord analytique

### 9.1 Test sur une nouvelle voiture

Tableau 16: Description du véhicule testé

| Caractéristique      | Valeur     |
|----------------------|------------|
| Année-Modèle         | 2021       |
| Kilométrage          | 65 000 km  |
| Puissance fiscale    | 7 CV       |
| Nombre de portes     | 5          |
| Nombre d'équipements | 10         |
| Ville                | Casablanca |
| Marque               | Dacia      |
| Modèle               | Duster     |
| Carburant            | Diesel     |
| Boîte de vitesses    | Manuelle   |

**Prédiction :** Le Random Forest optimisé estime le prix de ce véhicule à 175 787,67 DH.

Cette valeur représente une estimation du prix affiché et non une garantie du prix réel de vente. Elle dépend des caractéristiques saisies et des annonces utilisées pendant l'entraînement. Elle doit être considérée comme une aide à la décision, à compléter par une vérification de l'état du véhicule et une comparaison avec des annonces similaires.

### 9.2 Indicateurs du tableau de bord

Tableau 17: indicateurs clés du tableau de bord

| Indicateur                  | Valeur     |
|-----------------------------|------------|
| Nombre d'annonces nettoyées | 5 032      |
| Prix médian                 | 115 000 DH |
| Kilométrage médian          | 125 000 km |
| Marque la plus présente     | Volkswagen |




Figure 19: Diagramme à barres des marques de voitures les plus présentes dans les annonces




Figure 20: Diagramme à barres du prix médian des véhicules selon la marque (en DH)




Figure 21: Nombre d'annonces automobiles selon le type de carburant

Le tableau de bord présente trois graphiques complémentaires : les marques les plus présentes, le prix médian selon la marque et la répartition des types de carburant. Il contient également un tableau qui résume le nombre d'annonces, le prix médian, le kilométrage médian et la marque la plus représentée. Ces éléments permettent de comprendre rapidement la structure du dataset.

Volkswagen, Renault et Dacia sont les marques les plus représentées. Le diesel domine largement les annonces, tandis que l'essence, l'hybride et l'électrique sont beaucoup moins présents. Le graphique du prix médian selon la marque montre également qu'Audi et Mercedes-Benz présentent les prix médians les plus élevés parmi les principales marques.

## Conclusion générale

Ce projet a permis de mettre en œuvre une chaîne complète d'analyse des annonces automobiles. Le script de scraping sépare la collecte des liens et l'extraction des détails. Il gère également les délais, les erreurs, les pages incomplètes et la reprise après interruption. Le dataset obtenu contient **5 242 annonces**, ce qui dépasse largement le minimum demandé.

Le prétraitement a permis de traiter les valeurs manquantes, les doublons, les formats textuels et les valeurs aberrantes. Après nettoyage, le dataset contient **5 032 annonces**. Les variables catégorielles ont été encodées et les variables numériques standardisées dans un pipeline afin d'appliquer les mêmes traitements pendant l'entraînement, le test et l'inférence.

L'analyse exploratoire montre que le prix est notamment lié à l'année du véhicule, au nombre d'équipements, à la puissance fiscale et au kilométrage. Trois modèles ont été comparés : la régression linéaire, Random Forest et XGBoost. XGBoost obtient les meilleurs résultats avant optimisation. Après l'utilisation de `GridSearchCV`, le Random Forest optimisé est retenu comme modèle final. Il obtient une **MAE de 35 627,69 DH**, un **RMSE de 116 404,72 DH** et un **R<sup>2</sup> de 0,5432**. Le modèle reste toutefois moins précis pour les véhicules rares ou très chers.

Le clustering K-Means complète l'analyse prédictive. Le meilleur Silhouette Score est obtenu avec deux clusters, avec une valeur de **0,4494**. Le premier cluster regroupe des véhicules plus récents, plus chers, mieux équipés et moins kilométrés. Le second regroupe des véhicules plus anciens, moins chers, moins équipés et davantage kilométrés.

Enfin, le test d'inférence sur une Dacia Duster produit un prix estimé de **175 787,67 DH**. Le tableau de bord permet de résumer les principales caractéristiques du marché à partir du nombre d'annonces, du prix médian, des marques et des types de carburant.

## Limites et perspectives

### Limites du projet

Ce projet présente plusieurs limites. Les prix utilisés correspondent aux prix affichés dans les annonces et non aux prix réellement négociés lors de la vente. Certaines informations importantes,

comme l'état mécanique précis, l'historique d'entretien, les accidents ou la finition exacte du véhicule, ne sont pas disponibles dans le dataset.

Les données sont également dominées par les véhicules diesel et par certaines marques très représentées. Les véhicules très chers sont peu nombreux, ce qui rend leurs prix plus difficiles à prédire. Enfin, le scraping dépend de la structure HTML du site Avito et certains champs ne sont pas toujours renseignés par les vendeurs.

## **Perspectives d'amélioration**

Plusieurs améliorations peuvent être envisagées. Il serait possible d'analyser le texte des descriptions et les images des annonces afin d'obtenir davantage d'informations. D'autres variables pourraient être ajoutées, comme l'âge du véhicule, la finition ou la date de publication.

Une grille d'hyperparamètres plus large et d'autres modèles pourraient également être testés. Le projet pourrait aussi être complété par une application Web permettant de saisir les caractéristiques d'un véhicule et d'obtenir une estimation de prix. Enfin, le dataset pourrait être actualisé régulièrement afin de suivre l'évolution du marché automobile.